



# Tabelle hash




# Richiamo TDA mappa ( 9.1)



## ◆ Metodi del TDA mappa:

- **get(k)**: se la mappa M ha una entry con chiave k, restituisce il valore ad essa associato, altrimenti restituisce null
- **put(k, v)**: inserisce nella mappa M la entry (k, v); se la chiave k non è già in M restituisce il risultato null; altrimenti, se w è il valore già presente associato a k, sostituisce w con v, restituendo come risultato proprio w
- **remove(k)**: se la mappa M ha una entry con chiave k, rimuove tale entry da M e restituisce il valore associato a k; altrimenti, restituisce null
- **size()**, **isEmpty()**
- **keys()**: restituisce una collection iterabile contenente tutte le chiavi contenute in M (**keys().iterator()** restituisce un iteratore alle chiavi)
- **values()**: restituisce una collection iterabile contenente tutti i valori associati alle chiavi contenute in M (**values().iterator()** restituisce un iteratore ai valori)
- **entries()**: restituisce una collection iterabile contenente tutte le entry chiave-valore contenute in M (**entries().iterator()** restituisce un iteratore alle entry)


# Funzioni hash e tabelle hash ( 9.2)



- ◆ Una **funzione hash**  $h$  trasforma (mappa) chiavi di una data tipologia in interi appartenenti a un intervallo prefissato  $[0, N - 1]$
- ◆ Esempio:  
$$h(x) = x \bmod N$$
  
è una funzione hash per chiavi intere
- ◆ L'intero  $h(x)$  è detto **codice hash** della chiave  $x$
- ◆ Una **tabella hash** per una data tipologia di chiavi consiste di
  - una funzione hash  $h$
  - un array (tabella) di dimensione  $N$
- ◆ Nell'implementazione di una mappa attraverso una tabella hash, l'obiettivo è memorizzare l'elemento  $(k, o)$  nella posizione  $i = h(k)$

# Esempio

- ◆ Possibile tabella hash per una mappa che memorizza entry del tipo (SSN, Nome), dove SSN (social security number) è un intero positivo di nove cifre
- ◆ La Tabella hash usa un array di dimensione  $N = 10000$  e la funzione hash  $h(x) =$  ultime quattro cifre di  $x$



# Funzioni Hash (§ 9.2.2)



- ◆ Una funzione hash è di solito specificata come composizione di due funzioni:

**Codice hash:**

$h_1$ : chiavi  $\rightarrow$  interi

**Funzione di compressione:**


$h_2$ : interi  $\rightarrow [0, N - 1]$

- ◆ Si applica dapprima il codice hash; successivamente la funzione di compressione viene applicata sul risultato, cioè

$$h(x) = h_2(h_1(x))$$

- ◆ L'obiettivo della funzione hash è "disperdere" le chiavi in maniera apparentemente casuale

# Codici Hash ( 9.2.3)



## ◆ Codici hash in Java:

- Si interpreta l'indirizzo di memorizzazione dell'oggetto chiave come intero (metodo `java.lang.Object.hashCode()`, che restituisce un `int`)
- Buono in generale, eccetto che per chiavi numeriche e stringhe

## ◆ Assegnazione a un numero intero:

- Si reinterpretano i bit della chiave come intero
- Tecnica idonea per chiavi di lunghezza non superiore al numero di bit del tipo intero (in Java: `byte`, `short`, `int`, `float`)

## ◆ Somma di componenti:

- Si partizionano i bit della chiave in componenti di lunghezza prefissata (ad es., 16 o 32 bit) e si sommano tali componenti (ignorando gli overflow)
- Idonea per chiavi numeriche di lunghezza almeno uguale al numero di bit del tipo intero (in Java: `long` e `double`)

# Codici hash (cont.)

## ◆ Codici hash polinomiali:

- Si partizionano i bit della chiave in una sequenza di componenti di lunghezza fissata (ad es., 8, 16 o 32 bit)

$$a_0 a_1 \dots a_{n-1}$$

- Si valuta il polinomio

$$p(z) = a_0 + a_1 z + a_2 z^2 + \dots \\ \dots + a_{n-1} z^{n-1}$$

su un valore  $z$  prefissato, ignorando gli eventuali overflow

- Particolarmente idoneo su stringhe (ad es., la scelta  $z = 33$  determina al più 6 collisioni in un insieme di 50000 vocaboli della lingua inglese)

◆ Il polinomio  $p(z)$  può essere valutato in tempo  $O(n)$  usando la regola di Horner:

- calcolare in sequenza i seguenti polinomi, ciascuno ottenuto dal precedente in tempo  $O(1)$

$$p_0(z) = a_{n-1}$$

$$p_i(z) = a_{n-i-1} + z p_{i-1}(z) \\ (i = 1, 2, \dots, n-1)$$

- Vale  $p(z) = p_{n-1}(z)$

# Funzioni di compressione ( 9.2.4)



## ◆ Il metodo di divisione:


- $h_2(y) = y \bmod N$
- La dimensione  $N$  della tabella hash viene di solito scelta come numero primo
- Se  $N$  non è primo, eventuali pattern nella distribuzione di codici hash possono ripetersi nella distribuzione dei valori hash, causando collisioni

## ◆ Il metodo MAD (moltiplicazione, addizione e divisione):


- $h_2(y) = |ay + b| \bmod N$
- $a$  e  $b$  sono interi casuali tali che
  - ◆  $a > 0$
  - ◆  $a \bmod N \neq 0$
  - ◆  $b \geq 0$
- Se  $a \bmod N = 0$  ogni intero verrebbe trasformato nello stesso valore  $b$



# Gestione delle collisioni (§ 9.2.5)



- ◆ Si verificano collisioni quando elementi differenti vengono mappati nella stessa cella
- ◆ **Concatenazione separata:** ad ogni cella nella tabella viene associata una lista collegata di entry che vengono mappate in quella stessa cella



- ◆ La concatenazione separata è semplice ma richiede spazio di memoria aggiuntivo all'esterno della tabella

# Metodi della mappa con gestione collisioni a concatenazione separata

◆ Tabella hash con concatenazione separata: metodi fondamentali.

**Algorithm** get( $k$ ):

**Output:** Il valore associato alla chiave  $k$  della mappa, o **null** se non esiste nessuna entry con chiave  $k$

**return**  $A[h(k)].get(k)$       {delega il get alla mappa basata su lista a  $A[h(k)]$ }

**Algorithm** put( $k, v$ ):

**Output:** Se esiste una entry con chiave  $k$ , restituisce il suo valore (che viene sostituito da  $v$ ); altrimenti restituisce **null**

$t = A[h(k)].put(k, v)$       {delega il put alla mappa basata su lista a  $A[h(k)]$ }

**if**  $t = \text{null}$  **then**      { $k$  è una chiave nuova}

$n = n + 1$

**return**  $t$

**Algorithm** remove( $k$ ):

**Output:** Il valore (cancellato) associato alla chiave  $k$ , o **null** se non esiste la chiave  $k$  nella mappa

$t = A[h(k)].remove(k)$       {delega il remove alla mappa basata su lista a  $A[h(k)]$ }

**if**  $t \neq \text{null}$  **then**      { $k$  trovata}

$n = n - 1$

**return**  $t$

# Linear probing

- ◆ **Indirizzamento aperto:** l'elemento collidente viene inserito in un'altra cella della tabella
- ◆ **Linear probing** gestisce le collisioni piazzando l'elemento collidente nella prossima (in senso circolare) cella disponibile della tabella
- ◆ Ciascuna ispezione di cella viene denominata "probe"
- ◆ Elementi collidenti tendono ad ammassarsi, causando future sequenze di probe più lunghe


## ◆ Esempio:

- $h(x) = x \bmod 13$
- Inserimento ordinato delle chiavi 18, 41, 22, 44, 59, 32, 31, 73

0	1	2	3	4	5	6	7	8	9	10	11	12

↓

		41			18	44	59	32	22	31	73	
0	1	2	3	4	5	6	7	8	9	10	11	12



# Ricerca con linear probing

◆ Consideriamo una tabella hash  $A$  che usa linear probing

◆  $get(k)$

- si inizia dalla cella  $h(k)$
- si sondano locazioni consecutive finché non accade uno dei seguenti eventi
  - ◆ viene trovata una entry con chiave  $k$ , oppure
  - ◆ viene trovata una cella vuota, oppure
  - ◆ sono state infruttuosamente sondate  $N$  celle

**Algorithm**  $get(k)$

$i \leftarrow h(k)$

$p \leftarrow 0$

**repeat**

$c \leftarrow A[i]$

**if**  $c = \emptyset$

**return** *null*

**else if**  $c.key() = k$

**return**  $c.element()$

**else**

$i \leftarrow (i + 1) \bmod N$

$p \leftarrow p + 1$

**until**  $p = N$

**return** *null*

# Aggiornamenti con il linear probing

- ◆ Per gestire inserimenti e cancellazioni, introduciamo un oggetto speciale (sentinella) chiamato AVAILABLE che sostituisce gli elementi eliminati


- ◆ **remove( $k$ )**

- si cerca una entry con chiave  $k$
- se viene trovata una entry  $(k, o)$ , questa viene sostituita con la sentinella e viene restituito l'elemento  $o$
- Altrimenti, si restituisce *null*

- ◆ **put( $k, o$ )**

- si lancia eccezione se la tabella è piena
- si inizia a cella  $h(k)$
- si sondano consecutivamente le celle finché non viene trovata una cella  $i$  vuota o con l'oggetto sentinella
  - ◆ ciò accadrà sicuramente altrimenti sarebbe stata lanciata un'eccezione
- memorizziamo la entry  $(k, o)$  nella cella  $i$

# Hashing doppio



- ◆ Lo hashing doppio usa una funzione di hash secondaria  $d(k)$  e gestisce le collisioni posizionando gli elementi collidenti nella cella  $i$  nella prima cella disponibile secondo lo schema

$$(i + j d(k)) \bmod N$$

per  $j = 0, 1, \dots, N - 1$

- ◆ La funzione  $d(k)$  non può avere valori nulli
- ◆ La dimensione  $N$  della tabella deve essere un numero primo per garantire il probe di tutte le sue celle

- ◆ Una scelta comune della funzione di compressione per la funzione hash secondaria è:

$$d_2(k) = q - (k \bmod q)$$

dove

- $q < N$
- $q$  è un numero primo
- ◆ I valori possibili di  $d_2(k)$  sono  
 $1, 2, \dots, q$

# Esempio di hashing doppio

◆ Si consideri una tabella hash a chiavi intere che gestisce le collisioni con hashing doppio

- $N = 13$
- $h(k) = k \bmod 13$
- $d(k) = 7 - k \bmod 7$

◆ Inserimento ordinato delle chiavi 18, 41, 22, 44, 59, 32, 31, 73


$k$	$h(k)$	$d(k)$	Probes	
18	5	3	5	
41	2	1	2	
22	9	6	9	
44	5	5	5	10
59	7	4	7	
32	6	3	6	
31	5	4	5	9 0
73	8	4	8	

0	1	2	3	4	5	6	7	8	9	10	11	12



31		41			18	32	59	73	22	44		
0	1	2	3	4	5	6	7	8	9	10	11	12

# Le prestazioni dello hashing



- ◆ Nel caso peggiore, ricerche, inserimenti ed eliminazioni richiedono tempo  $O(n)$
- ◆ Il caso peggiore si verifica quando tutti gli inserimenti causano collisione
- ◆ Le prestazioni in pratica risentono del fattore di carico  $\alpha = n/N$
- ◆ Assumendo che i valori hash abbiano una distribuzione uniforme, si può dimostrare che il numero atteso di probe per inserimento, utilizzando l'indirizzamento aperto, è  $1 / (1 - \alpha)$
- ◆ Il tempo atteso di ogni operazione in una tabella hash è  $O(1)$
- ◆ In pratica, lo hashing è estremamente veloce purché il fattore di carico non sia troppo vicino al 100%
- ◆ Applicazioni delle tabelle hash:
  - piccoli database
  - compilatori
  - cache dei browser



# Java Example

```
/** A hash table with linear probing and the MAD hash function */
public class HashTable implements Map {
    protected static class HashEntry implements Entry {
        Object key, value;
        HashEntry () { /* default constructor */ }
        HashEntry(Object k, Object v) { key = k; value = v; }
        public Object key() { return key; }
        public Object value() { return value; }
        protected Object setValue(Object v) { // set a new value, returning old
            Object temp = value;
            value = v;
            return temp; // return old value
        }
    }
    /** Nested class for a default equality tester */
    protected static class DefaultEqualityTester implements EqualityTester {
        DefaultEqualityTester() { /* default constructor */ }
        /** Returns whether the two objects are equal. */
        public boolean isEqualTo(Object a, Object b) { return a.equals(b); }
    }
    protected static Entry AVAILABLE = new HashEntry(null, null); // empty
    marker
    protected int n = 0; // number of entries in the dictionary
    protected int N; // capacity of the bucket array
    protected Entry[] A; // bucket array
    protected EqualityTester T; // the equality tester
    protected int scale, shift; // the shift and scaling factors
    /** Creates a hash table with initial capacity 1023. */
    public HashTable() {
        N = 1023; // default capacity
        A = new Entry[N];
        T = new DefaultEqualityTester(); // use the default equality tester
        java.util.Random rand = new java.util.Random();
        scale = rand.nextInt(N-1) + 1;
        shift = rand.nextInt(N);
    }
}
```

```
/** Creates a hash table with the given capacity and equality tester. */
public HashTable(int bN, EqualityTester tester) {
    N = bN;
    A = new Entry[N];
    T = tester;
    java.util.Random rand = new java.util.Random();
    scale = rand.nextInt(N-1) + 1;
    shift = rand.nextInt(N);
}
```

# Java Example (cont.)

```

/** Determines whether a key is valid. */
protected void checkKey(Object k) {
    if (k == null) throw new InvalidKeyException("Invalid key: null.");
}
/** Hash function applying MAD method to default hash code. */
public int hashValue(Object key) {
    return Math.abs(key.hashCode()*scale + shift) % N;
}
/** Returns the number of entries in the hash table. */
public int size() { return n; }
/** Returns whether or not the table is empty. */
public boolean isEmpty() { return (n == 0); }
/** Helper search method - returns index of found key or -index-1,
 * where index is the index of an empty or available slot. */
protected int findEntry(Object key) throws InvalidKeyException {
    int avail = 0;
    checkKey(key);
    int i = hashValue(key);
    int j = i;
    do {
        if (A[i] == null) return -i - 1; // entry is not found
        if (A[i] == AVAILABLE) { // bucket is deactivated
            avail = i; // remember that this slot is available
            i = (i + 1) % N; // keep looking
        }
        else if (T.isEqualTo(key, A[i].key())) // we have found our entry
            return i;
        else // this slot is occupied--we must keep looking
            i = (i + 1) % N;
    } while (i != j);
    return -avail - 1; // entry is not found
}
/** Returns the value associated with a key. */
public Object get (Object key) throws InvalidKeyException {
    int i = findEntry(key); // helper method for finding a key
    if (i < 0) return null; // there is no value for this key
    return A[i].value(); // return the found value in this case
}

```

```

/** Put a key-value pair in the map, replacing previous one if it exists. */
public Object put (Object key, Object value) throws InvalidKeyException {
    if (n >= N/2) rehash(); // rehash to keep the load factor <= 0.5
    int i = findEntry(key); // find the appropriate spot for this entry
    if (i < 0) { // this key does not already have a value
        A[-i-1] = new HashEntry(key, value); // convert to the proper index
        n++;
        return null; // there was no previous value
    }
    else // this key has a previous value
        return ((HashEntry) A[i]).setValue(value); // set new value & return old
}
/** Doubles the size of the hash table and rehashes all the entries. */
protected void rehash() {
    N = 2*N;
    Entry[] B = A;
    A = new Entry[N]; // allocate a new version of A twice as big as before
    java.util.Random rand = new java.util.Random();
    scale = rand.nextInt(N-1) + 1; // new hash scaling factor
    shift = rand.nextInt(N); // new hash shifting factor
    for (int i=0; i<B.length; i++)
        if ((B[i] != null) && (B[i] != AVAILABLE)) { // if we have a valid entry
            int j = findEntry(B[i].key()); // find the appropriate spot
            A[-j-1] = B[i]; // copy into the new array
        }
}
/** Removes the key-value pair with a specified key. */
public Object remove (Object key) throws InvalidKeyException {
    int i = findEntry(key); // find this key first
    if (i < 0) return null; // nothing to remove
    Object toReturn = A[i].value();
    A[i] = AVAILABLE; // mark this slot as deactivated
    n--;
    return toReturn;
}
/** Returns an iterator of keys. */
public java.util.Iterator keys() {
    List keys = new NodeList();
    for (int i=0; i<N; i++)
        if ((A[i] != null) && (A[i] != AVAILABLE))
            keys.insertLast(A[i].key());
    return keys.elements();
}
// ... values() is similar to keys() and is omitted here ...

```